GENÔMICA DE BACTERIÓFAGOS

Descoberta de Holinas através da Bioinformática

Da análise de genomas à identificação de proteínas de membrana com potencial antimicrobiano — química, pipelines e estaca tecnológica.

Deraldo Duran
Universidade Federal do Ceará — UFC

Igor Alves
Especialista em Bioinformática — UQAM, Canadá

Seminário · 2026

O PROBLEMA

A resistência antimicrobiana supera o ritmo da descoberta

Pressão seletiva

Uso intensivo de antibióticos seleciona linhagens com β-lactamases, bombas de efluxo e paredes celulares modificadas.

Poucos alvos novos

A maioria das classes em uso atinge os mesmos quatro processos: parede celular, ribossomo, DNA girase e folato.

Janela longa

Da descoberta ao uso clínico passam-se mais de dez anos — o gargalo inicial é justamente achar o candidato.

A OMS classifica a resistência antimicrobiana como uma das principais ameaças à saúde global. Precisamos ampliar o espaço de busca por novos mecanismos líticos.

Fonte: World Health Organization — Antimicrobial Resistance Fact Sheet

INSPIRAÇÃO NATURAL

Bacteriófagos lisam bactérias há bilhões de anos

- Vírus que infectam exclusivamente bactérias — estimados em 10^{31} partículas na biosfera.
- Ao final do ciclo lítico, o fago precisa romper o envelope da célula hospedeira para liberar a progênie.
- Para isso, codifica um pequeno módulo de genes: o **cassete de lise**.

O cassete de lise canônico

```
… | holina | endolisina | spanina | …
```

Holina — proteína de membrana que define o *momento* da lise.

Endolisina — hidrolase que degrada o peptidoglicano.

Spanina — rompe a membrana externa em Gram-negativas.

O QUE SÃO HOLINAS

Proteínas pequenas e hidrofóbicas que formam poros na membrana interna

50–150
aminoácidos — entre as menores proteínas funcionais de um genoma viral

1–4
domínios transmembrana (TMD), que definem as classes I, II e III

+ carga
cauda C-terminal rica em Lys e Arg, altamente carregada e citoplasmática

≈ 0
homologia de sequência entre famílias — o motivo pelo qual BLAST sozinho falha

Analogia: se a bactéria é uma fortaleza, a endolisina é o aríete — e a holina é o relógio que decide a hora exata de abrir o portão.

QUÍMICA DO ALVO

O envelope que a holina atravessa

Membrana interna

Bicamada fosfolipídica de *E. coli*, cerca de 4 nm de espessura:

Lipídeo	Fórmula
Fosfatidiletanolamina	$C_{37}H_{74}NO_8P$
Fosfatidilglicerol	$C_{40}H_{77}O_{10}P$
Cardiolipina	$C_{81}H_{156}O_{17}P_2$

O interior apolar dessa bicamada é o que exige hélices transmembrana hidrofóbicas — a assinatura que o computador procura.

Parede de peptidoglicano

Polímero alternado unido por ligações β-1,4:

$$[\ \text{GlcNAc} - \text{MurNAc}\ ]_n$$

GlcNAc: $C_8H_{15}NO_6$

MurNAc: $C_{11}H_{19}NO_8$

Pentapeptídeo haste em Gram-negativas:
L-Ala – D-Glu – m-DAP – D-Ala – D-Ala

É esse polímero que a endolisina hidrolisa — mas só depois que a holina lhe dá acesso.

Força próton-motriz

O gradiente eletroquímico que a membrana sustenta:

$$\Delta p = \Delta\psi - (2{,}303 \cdot RT/F) \cdot \Delta pH$$

A 25 °C, o termo de pH vale ≈ 59 mV por unidade. Em *E. coli*, Δψ fica entre −120 e −160 mV.

A despolarização desse Δψ é o gatilho do sistema — não uma reação química de clivagem.

Fórmulas moleculares das espécies lipídicas predominantes (16:0/18:1); composição varia com a fase de crescimento.

MECANISMO

Um relógio molecular, não um interruptor

#	Evento	Química envolvida	Observável
1	Expressão do cassete	Transcrição tardia do fago	RNA-seq tardio
2	Inserção na bicamada	Particionamento apolar, $\Delta G < 0$	Hidrofobicidade
3	Oligomerização	Interações hélice–hélice	Microscopia
4	Acionamento	Colapso de $\Delta\psi$ ao atingir limiar	Potencial de membrana
5	Formação do poro	Canal permeável a proteínas	Queda de OD_{600}
6	Hidrólise da parede	Endolisina cliva β-1,4 + H_2O	Zimograma
7	Lise e liberação	Turgor rompe o envelope	Contagem de PFU

A etapa 4 é a razão de existir da holina: a concentração crítica funciona como temporizador da lise.

Modelo clássico de Young & Bläsi (1995) e revisões subsequentes sobre o *lysis clock*.

A ASSINATURA COMPUTACIONAL

Sem homologia, procuramos física

Como as famílias de holina quase não compartilham sequência, o pipeline não busca *palavras* parecidas: busca propriedades físico-químicas que a função impõe.

Hidrofobicidade média (GRAVY)

$$GRAVY = \left(\Sigma\ h_i \right) / n$$

Escala de Kyte–Doolittle; janela de 19 resíduos. Picos acima de +1,6 indicam hélice transmembrana.

Regra do interior positivo

$$q = n(Lys) + n(Arg) - n(Asp) - n(Glu)$$

Caudas citoplasmáticas de holina têm q fortemente positivo — critério simples e muito discriminante.

Os sete filtros que definem um candidato

Critério	Faixa esperada
Comprimento	50 a 150 aminoácidos
Domínios transmembrana	1 a 4 hélices preditas
GRAVY global	> 0,4 (hidrofóbico)
Carga da cauda C-terminal	q ≥ +3
Peptídeo-sinal clássico	Ausente (SignalP negativo)
Contexto genômico	Vizinho de endolisina predita
Fase de leitura sobreposta	Frequente — antiholina em ORF embutida

O filtro mais forte não é a proteína isolada, e sim a **sintenia**: holina e endolisina aparecem juntas no genoma.

A ESCALA DO PROBLEMA

Achar algumas proteínas em milhões de sequências

~30 mil

genomas completos de bacteriófagos em bases públicas curadas, como INPHARED e NCBI Virus

milhões

de contigs virais em metagenomas — IMG/VR e bases de viromas ampliam a busca em ordens de magnitude

60–80%

das proteínas preditas em fagos não têm função atribuída — a chamada *matéria escura* viral

1 por vez

é o ritmo da bancada: clonar, expressar e testar cada candidato leva semanas

A função do pipeline não é substituir o laboratório — é entregar à bancada uma lista de dez candidatos em vez de dez mil.

Ordens de magnitude aproximadas; bases de dados crescem continuamente.

O PIPELINE

Nove etapas, de genoma bruto a candidato priorizado

01 · Aquisição
Genomas de fago
INPHARED
NCBI Virus
IMG/VR

→

02 · Qualidade
Triagem viral
fastp
CheckV
geNomad

→

03 · Genes
Predição de ORFs
Prodigal-gv
PHANOTATE

→

04 · Homologia
Busca remota
DIAMOND
HMMER + Pfam
PHROG

→

05 · Topologia
Hélices TMD
DeepTMHMM
Phobius
TMbed

06 · Físico-química
GRAVY, carga, pI
Biopython
ProtParam

→

07 · Estrutura
Dobramento e busca
ColabFold
AlphaFold2
Foldseek

→

08 · Aprendizado
Classificação
ESM-2 embeddings
XGBoost
scikit-learn

→

09 · Contexto
Sintenia do cassete
Clinker
Pharokka

→

Saída
Candidatos ranqueados
candidates.tsv + relatório

Ferramentas livres e de uso acadêmico corrente; as versões ficam fixadas no arquivo de ambiente do pipeline.

COMO ISSO É ESCRITO

O pipeline em código — reprodutível e paralelo

Orquestração — Nextflow DSL2

```
workflow {
  genomas = Channel.fromPath(params.fasta)
  PRODIGAL_GV(genomas)
    | DEEPTMHMM
    | PROTPARAM
    | ESM2_EMBED
    | RANK_CANDIDATES
}
process DEEPTMHMM {
  container 'biocontainers/deeptmhmm:1.0.24'
  cpus 8
  input:  path faa
  output: path 'topology.gff3'
}
```

Cada etapa roda em contêiner com versão fixada; o cache de execução permite retomar de onde parou.

Filtro físico-químico — Biopython

```
from Bio.SeqUtils.ProtParam import ProteinAnalysis
GRAVY_MIN, Q_MIN = 0.4, 3
def candidato(seq, n_tmd, cauda):
    pa = ProteinAnalysis(str(seq))
    gravy = pa.gravy()  # Kyte-Doolittle
    q = (cauda.count('K') + cauda.count('R')
         - cauda.count('D') - cauda.count('E'))
    return (50 ⩽ len(seq) ⩽ 150
            and 1 ⩽ n_tmd ⩽ 4
            and gravy > GRAVY_MIN
            and q ⩾ Q_MIN)
```

São os sete critérios do slide anterior em dez linhas — baratos de calcular sobre milhões de sequências.

A ESTACA TECNOLÓGICA

O que sustenta o pipeline por baixo

Camada	Tecnologias	Para que serve
Dados e formatos	FASTA, GFF3, Parquet, DuckDB	Sequências, anotações e tabelas de atributos
Bases de referência	INPHARED, NCBI Virus, Pfam, PHROG, UniProt	Genomas de entrada e perfis de domínio
Ambiente	Conda/Bioconda, Docker, Apptainer	Versões fixadas e execução reprodutível
Orquestração	Nextflow DSL2 ou Snakemake, nf-core	Paralelismo, retomada e proveniência
Computação	Cluster HPC com SLURM; nuvem com S3 e filas de lote	Escala horizontal para milhares de genomas
Aceleração	GPU NVIDIA com CUDA	Predição estrutural e modelos de linguagem de proteína
Aprendizado de máquina	PyTorch, ESM-2, scikit-learn, XGBoost	Embeddings e classificação de candidatos
Análise e relato	Python com Biopython, R com tidyverse, Jupyter, Quarto	Estatística, figuras e relatório final
Rastreabilidade	Git, DVC, MLflow, arquivos de ambiente versionados	Reproduzir qualquer resultado meses depois

Toda a pilha é composta de software livre; a mesma configuração roda em notebook, cluster institucional ou nuvem.

APRENDIZADO DE MÁQUINA

Modelos de linguagem de proteína enxergam o que o BLAST não vê

O que ganhamos

- Um **embedding** do ESM-2 representa a proteína em centenas de dimensões, capturando semelhança funcional sem semelhança de sequência.
- Busca estrutural com Foldseek encontra parentes a partir da *forma* predita, não do alfabeto.
- Um classificador treinado em holinas conhecidas ordena os desconhecidos por probabilidade.
- Resultado prático: a lista que vai à bancada encurta uma ou duas ordens de magnitude.

O que isso não resolve

- Poucos exemplos positivos rotulados — algumas centenas de holinas caracterizadas, contra milhões de sequências.
- Risco de o modelo aprender a **base de dados** em vez da biologia; exige validação cruzada por família.
- Proteínas de membrana são justamente as mais difíceis de predizer estruturalmente.
- Nenhuma probabilidade alta substitui um experimento: o modelo prioriza, não conclui.

A IA não substitui o laboratório — ela decide a ordem da fila.

DA PREDIÇÃO À PROVA

O computador aponta; a bancada confirma

ETAPA 1

Predição in silico

Nove etapas do pipeline, poucas horas de cluster, custo marginal por genoma próximo de zero.

Entrega: tabela ranqueada com atributos, estrutura predita e vizinhança genômica de cada candidato.

ETAPA 2

Caracterização in vitro

Síntese do gene, expressão sob promotor induzível e acompanhamento do cultivo por densidade óptica (OD_{600}).

Confirma: localização na membrana, efeito sobre o potencial Δψ e dependência da endolisina.

ETAPA 3

Aplicação

Engenharia de fagos terapêuticos com temporização de lise ajustada; biocontrole na indústria de alimentos.

Também: ferramentas de biologia molecular para lise controlada de culturas em laboratório.

Trabalho com fagos e proteínas líticas segue as normas de biossegurança da instituição e, no caso terapêutico, a regulação sanitária aplicável. A triagem computacional antecede — e não dispensa — essa avaliação.

Fluxo padrão de genômica funcional: predição, confirmação fenotípica, aplicação.

CONCLUSÃO

Quatro ideias para levar daqui

01

A resistência antimicrobiana exige ampliar o espaço de busca por mecanismos líticos — e os fagos já resolveram esse problema por conta própria.

02

Holinas controlam o *momento* da lise despolarizando a membrana interna; sua função nasce da física da bicamada, não de um sítio catalítico.

03

Como não há homologia a explorar, a bioinformática busca hidrofobicidade, carga, topologia e sintenia — propriedades calculáveis a partir da sequência.

04

Pipeline reprodutível, contêineres e modelos de linguagem de proteína transformam uma triagem inviável em uma lista curta para a bancada.

REFERÊNCIAS

Literatura citada

1. World Health Organization. *Antimicrobial Resistance Fact Sheet*, 2026.
2. Young R., Bläsi U. Holins: form and function in bacteriophage lysis. *FEMS Microbiology Reviews*, 1995.
3. Saier M. H., Reddy B. L. Holins in Bacteria, Eukaryotes and Archaea. *Journal of Bacteriology*, 2015.
4. Abeysekera G. S. et al. Bacteriophage-encoded lethal membrane disruptors. *Frontiers in Microbiology*, 2022.
5. Pollenz R. S. et al. Bioinformatic characterization of holin-like membrane proteins. *PLOS ONE*, 2022.
6. Shi Y. et al. Characterization of the holin protein of bacteriophage SMP. *Virology Journal*, 2012.
7. Kyte J., Doolittle R. F. A simple method for displaying the hydropathic character of a protein. *Journal of Molecular Biology*, 1982.

Ferramentas e bases

Recurso	Uso no pipeline
INPHARED / NCBI Virus	Genomas de bacteriófagos
Prodigal-gv / PHANOTATE	Predição de genes virais
HMMER + Pfam / PHROG	Perfis de domínio
DeepTMHMM / Phobius	Topologia de membrana
Biopython ProtParam	GRAVY, carga, pI
ColabFold / Foldseek	Estrutura e busca estrutural
ESM-2 / PyTorch	Embeddings de proteína
Nextflow / Apptainer	Execução reprodutível

Obrigado. Perguntas?

Deraldo Duran · UFC

Igor Alves · Especialista em Bioinformática, UQAM